

Estadística descriptiva

Andrés Felipe Puerta Velez

xxxxxxx@uniminuto.edu.co

CBASBL031 - CBASBL141

Sesión 1 — Semana 1 · 10 al 15 de agosto de 2026

Orden del día

1. Llamado a lista, presentación del grupo y elección del representante
2. Para qué sirve la estadística: tres historias y tres preguntas
3. Temario, cronograma, evaluación y acuerdos mínimos
4. **Tema 1.1: población, muestra, unidad de observación, variable y dato**
5. Cómo se produce un dato y cómo se guarda: la matriz de datos
6. De dónde salen los datos: censo, muestra y sesgos de recolección
7. Cómo se lee mal una estadística; taller de diseño y cierre

Sesión de 3 horas. Al final de hoy queda definido el **conjunto de datos** que acompañará todo el semestre.

¿Para qué sirve la estadística descriptiva?

Un conjunto de datos en bruto no dice nada. **Describir** es convertirlo en algo que se pueda leer, comparar y comunicar.

Lo que haremos

- Organizar datos en tablas
- Representarlos en gráficos
- Resumirlos en unos pocos números
- Interpretarlos y sustentar decisiones

Hasta dónde llega

La estadística descriptiva **resume lo que ya se observó**.

No afirma nada sobre los casos que **no** se midieron.

Esa disciplina no es una limitación: es lo que hace que un informe sea **defendible**.

Tres historias que hicieron la estadística

1854 — John Snow y el cólera en Londres

Cuando estalla un brote en el Soho, la teoría dominante culpa al "aire viciado". Snow hace otra cosa: **marca en un mapa dónde vivía cada muerto**. Las marcas se apiñan alrededor de una bomba de agua de la calle Broad. Convince a las autoridades de retirar la palanca de la bomba. **No tenía una teoría mejor: tenía los datos organizados.**

1858 — Florence Nightingale y el diagrama de la rosa

De vuelta de la guerra de Crimea, quiere convencer al gobierno británico de que la mayoría de los soldados no moría por heridas de combate sino por **enfermedades evitables en los hospitales**. Sabe que nadie va a leer su tabla, así que la convierte en un gráfico circular por meses. El gráfico funciona: **cambió la política sanitaria del ejército.**

1890 — el censo de Estados Unidos

El censo anterior había tardado casi ocho años en tabularse. Hermann Hollerith diseña una máquina de tarjetas perforadas para contarlo, y su empresa terminaría siendo parte de lo que hoy es **IBM**. **La informática nació, literalmente, de un problema estadístico.**

Las tres tienen la misma moraleja: **los datos no convencen solos**. Convencen cuando alguien los organiza, los representa y los interpreta. Eso es exactamente lo que vamos a aprender.

Cuatro preguntas que llegan a su escritorio

	Lo que le preguntan	Lo que hay que resolver primero
Psicología	"¿Cómo es el perfil de los estudiantes que llegan a consulta?"	¿Perfil en qué variables: edad, semestre, motivo de consulta? ¿Y cómo se resume cada una?
Psicología	"¿Cuánto tiempo espera un usuario para su primera cita?"	¿El tiempo <i>típico</i> es el promedio, la mitad o el más frecuente? Los tres pueden dar cifras distintas
T. Social	"¿El programa de acompañamiento familiar está funcionando?"	¿Funcionando en qué indicador, medido cómo y comparado con qué?
T. Social	"¿A qué comuna dirigimos los recursos del próximo semestre?"	¿Qué datos tengo, sobre cuántos casos, de qué periodo y de qué fuente?

Lo que este curso le da

Ninguna de las cuatro se responde con una fórmula suelta. Se responden con un **procedimiento**: definir bien la pregunta, organizar los datos, resumirlos con la medida adecuada e interpretarlos **sin decir más de lo que los datos permiten**.

En psicología y trabajo social los datos casi nunca son dinero: son **personas, casos y trayectorias**. Eso no cambia el procedimiento, pero sí sube el costo de equivocarse: detrás de cada fila de la tabla hay alguien.

La prueba de las cuatro frases

Afirmación	¿Se puede sostener?
“Los 40 usuarios encuestados esperaron en promedio 12 días.”	Sí: habla de los medidos
“Los usuarios del centro esperan en promedio 12 días.”	No: nadie midió a todos
“El 35 % de los encuestados asistió a todas las sesiones.”	Sí
“El 35 % de la población atendida asiste a todas las sesiones.”	No

La señal que las distingue

Fíjese en el **sujeto de la frase**. Si dice “los encuestados”, “los casos registrados” o “la muestra”, la afirmación se sostiene con los datos que tiene. Si dice “los usuarios” a secas, **está hablando de gente que nunca midió**.

La corrección casi siempre es de **redacción**, no de cálculo: basta con nombrar bien a quién se midió. Es el error que más se penaliza en los tres exámenes.

El curso en tres unidades

Unidad 1 (sem. 1–5)

Conceptos y tablas

Población y muestra, tipos de variables, escalas de medición, tablas de frecuencia y métodos gráficos.

Unidad 2 (sem. 7–11)

Medidas estadísticas

Tendencia central, posición, dispersión y forma; gráficos e interpretación de resultados.

Unidad 3 (sem. 13–15)

Análisis integrado

Aplicación completa a un conjunto de datos y sustentación de decisiones con evidencia.

Curso **100 % presencial** · 3 créditos · 16 semanas · 2 horas de clase por semana

Evaluación: tres exámenes, nada más

Evaluación	Semana y fechas	Peso
Examen 1 — Unidad 1	Semana 6: 14 al 19 de septiembre	35 %
Examen 2 — Unidad 2	Semana 12: 26 al 31 de octubre	35 %
Examen 3 — Unidad 3	Semana 16: 23 al 28 de noviembre	30 %
Total		100 %

Cómo son los exámenes

Individuales, en **Aulas Virtuales (Moodle)**, presentados de forma presencial en el aula y con tiempo límite. Selección múltiple con única respuesta y problemas de aplicación con respuesta numérica. Se permite calculadora y formulario.

Acuerdos mínimos del curso

- **No hay talleres, quices ni trabajos calificables.** Todo lo que hagamos en clase es formativo: sirve para prepararse.
- Las semanas **6, 12 y 16** se dedican por completo al examen; no se dictan temas nuevos.
- Notas y retroalimentación se publican dentro de la semana siguiente al examen.
Reclamaciones: 3 días hábiles.
- Presentación en fecha distinta solo con excusa válida radicada ante la coordinación del programa.
- Comunicación en clase, por correo institucional o por medio del representante de curso.
- Fraude o plagio anula la prueba y se reporta según el Reglamento Estudiantil.

Unidad 1. Conceptos básicos y tablas de distribución

1.1 Los cuatro conceptos de partida

Concepto	Definición	Ejemplo
Población	Conjunto <i>completo</i> de elementos sobre los que se quiere concluir. Tamaño N .	Los 1 200 clientes de la tienda
Muestra	Subconjunto de la población que sí se observa. Tamaño n .	40 clientes encuestados
Variable	Característica que se mide y que puede cambiar de un elemento a otro.	Gasto mensual, canal de compra
Dato	El valor concreto que toma la variable en un elemento.	\$35 000; "App"

Si algo no cambia entre los elementos no es una variable, es una **constante**: no aporta información para describir.

Población objetivo, población de estudio y marco muestral

Concepto	Qué es	En el ejemplo
Población objetivo	Sobre quién quiero concluir	Todos los clientes del almacén
Población de estudio	A quién puedo llegar de verdad	Los 1 200 clientes <i>registrados</i>
Marco muestral	La lista de la que se saca la muestra	La base de datos de registrados
Muestra	Los que efectivamente se midieron	Los 40 encuestados

Dónde se cuela el sesgo

En el salto de la primera fila a la segunda. Los clientes que compran y nunca se registran **no pueden salir en la muestra**, por más bien que se haga el muestreo. Si esos clientes son distintos —compran menos, o son de paso—, las conclusiones ya nacen torcidas.

Por eso un informe serio **declara las tres cosas**: sobre quién quería concluir, a quién pudo llegar y a quién midió. Es la diferencia entre un estudio y una encuesta improvisada.

Unidad de observación y variable: no confundirlas

Unidad de observación

El **elemento** del que se toman los datos: un cliente, una factura, un empleado, un pedido.

Responde a “¿de quién o de qué estoy midiendo?”.

Variable


La **característica** que se mide en esa unidad: el gasto, la edad, el canal de compra.

Responde a “¿qué estoy midiendo?”.

En una tabla de datos

Cada **fila** es una unidad de observación y cada **columna** es una variable. Es la estructura de un **data.frame** en R, y la misma en cualquier software estadístico.

De la realidad al dato: cómo se mide algo que no es un número



Las decisiones que se toman en el camino

"Satisfacción" no existe como número: **alguien decidió** medirla con una escala de 1 a 5, y no de 1 a 10, ni con una pregunta abierta. **Esa decisión es parte del resultado.** Dos encuestas que preguntan distinto no son comparables, aunque las dos hablen de satisfacción.

La pregunta que hay que hacerle a todo dato

¿Cómo se produjo este número? Un gasto de "227 mil" puede ser lo que el cliente *dijo* que gasta, lo que la caja *registró* o lo que el sistema *estimó*. Los tres se ven igual en la tabla y significan cosas distintas.

Ejercicio 1 — en clase

Individual (6 minutos)

Un supermercado quiere estudiar el comportamiento de compra de sus **1 200 clientes registrados**. Se encuesta a **40** de ellos y a cada uno se le pregunta el gasto del último mes y el canal por el que compró.

1. Identifique la población y su tamaño.
2. Identifique la muestra y su tamaño.
3. ¿Cuál es la unidad de observación?
4. Nombre las dos variables y dé un ejemplo de dato para cada una.

Ejercicio 1 — solución

Respuestas

- Población: los 1 200 clientes registrados, $N = 1\,200$.
- Muestra: los 40 encuestados, $n = 40$.
- Unidad de observación: **un cliente**.
- Variables: **gasto mensual** (dato: 35 mil) y **canal de compra** (dato: “App”).

Fíjese

El número 1 200 **no** es un dato del estudio: es el tamaño de la población.

Y “40” tampoco: es el tamaño de la muestra. Los datos son los 40 gastos y los 40 canales.

Las etapas del proceso estadístico

1. **Plantear la pregunta.** ¿Qué se quiere saber y sobre quién?
2. **Definir población y unidad de observación.**
3. **Elegir las variables** y cómo se van a medir.
4. **Recolectar los datos** (censo o muestra).
5. **Organizar:** tablas de frecuencia.
6. **Representar:** gráficos.
7. **Resumir:** medidas estadísticas.
8. **Interpretar y decidir.**

(sesión 3)

(sesión 4)

(unidad 2)

(unidad 3)

Dónde se pierde la mayoría de los estudios

En los pasos 1 a 3. Si la variable está mal definida o la unidad de observación es ambigua, **ningún cálculo posterior lo arregla.**

Estudio observacional o experimental

	Observacional	Experimental
Qué se hace	Se mira lo que pasa, sin intervenir	Se interviene y se compara con un grupo de control
Ejemplo	Registrar el gasto de los clientes que llegan	Poner una promoción en una sede y no en otra, y comparar
Qué permite decir	Que dos cosas van juntas	Que una causa la otra
Costo y control	Barato, pero con muchas explicaciones alternativas	Costoso, a veces imposible o no ético

Por qué se lo digo en la primera semana

Porque el error más caro de todo el curso es leer un estudio **observacional** y redactar una conclusión **causal**. "Los clientes que usan la app gastan más" **no** significa que la app los haga gastar más: puede que los que ya gastaban más sean justamente quienes se bajan la app.

Casi todo lo que veremos en este curso es observacional. Volveremos sobre esto en la unidad 3.

Ejercicio 2 — en clase

En parejas (8 minutos)

Para cada estudio, identifique la **unidad de observación** y proponga **dos variables** que tendría sentido medir.

1. Un hospital quiere caracterizar las consultas del último mes.
2. Una empresa quiere estudiar sus facturas de venta del año.
3. Un colegio quiere describir a sus docentes.
4. Una tienda quiere analizar sus pedidos a domicilio.

Ejercicio 2 — solución

#	Estudio	Unidad de observación	Variables posibles
1	Consultas del mes	Una consulta	Duración en minutos; especialidad
2	Facturas del año	Una factura	Valor facturado; forma de pago
3	Docentes	Un docente	Años de experiencia; nivel de formación
4	Pedidos a domicilio	Un pedido	Tiempo de entrega; canal del pedido

El error típico

Decir que la unidad del caso 1 es “el hospital”. El hospital es *uno solo*: si fuera la unidad, habría un solo dato y nada que describir. **La unidad es aquello de lo que hay muchos.**

De dónde salen los datos

Según quién los recogió

Primarios: los recoge usted para **esta** pregunta. Encuesta, observación, experimento. Más costosos, pero a la medida.

Secundarios: ya existían. Registros de la empresa, DANE, bases públicas. Baratos, pero fueron pensados para otra pregunta.

Según cuánto se mide

Censo: se mide **toda** la población. Exacto, pero costoso, lento y a veces imposible.

Muestra: se mide una parte. Más rápido y barato, y si está bien tomada, suficiente.

Por qué casi siempre se muestrea

Porque medir a los 1 200 clientes cuesta 30 veces más que medir a 40, y porque a veces la medición **destruye** la unidad: nadie prueba la resistencia de los 10 000 tornillos del lote, porque se quedaría sin lote.

Cómo se arruina un estudio antes de calcular nada

Problema	Ejemplo	Consecuencia
Muestra mal tomada	Encuestar solo los sábados en la mañana	Describe ese momento, no el negocio
Pregunta ambigua	“¿Cuánto gasta usted?” (¿al día? ¿al mes?)	Datos que no son comparables entre sí
Unidad mal definida	Contar “clientes” cuando el registro son facturas	Un cliente con 3 facturas cuenta tres veces
No respuesta selectiva	Los insatisfechos no contestan	Todo se ve mejor de lo que es

La regla que hay que interiorizar

Ningún cálculo arregla un dato mal recogido. Se puede calcular la media de datos basura con seis decimales, y sigue siendo basura con seis decimales.

Ejercicio 3 — en clase

Individual (8 minutos)

Una empresa con **850 empleados** encuesta a **120**. Parte de la tabla de datos se ve así:

Empleado	Área	Antigüedad (años)	Salario (miles)
1	Ventas	3	2 100
2	Operaciones	7	1 850
3	Ventas	1	1 950

1. ¿Cuántas filas y cuántas columnas de variables tiene la tabla completa?
2. Clasifique los números 850, 120, 7 y 1 850: ¿cuál es dato, cuál es tamaño de población y cuál de muestra?
3. ¿Es “Empleado” una variable?

Ejercicio 3 — solución

Puntos 1 y 2

- **120 filas** (una por empleado encuestado) y **3 columnas** de variables.
- $N = 850$ y $n = 120$ son **tamaños**, no datos.
- 7 y 1 850 sí son **datos**: valores de antigüedad y salario del empleado 2.

Punto 3

No. “Empleado” es el **identificador** de la unidad de observación: dice de quién es la fila, no qué se midió.

Ojo

Si el identificador fuera un número (1, 2, 3...), promediario daría un resultado sin ningún sentido. Es el mismo problema del código de sucursal que veremos en la sesión 2.

El conjunto de datos que usaremos todo el curso

Gasto mensual, en miles de pesos, de una muestra de $n = 40$ clientes del **Almacén Bello**:

112	127	138	149	153	158	165	171	178	184
190	195	199	203	208	212	215	219	222	226
229	231	234	238	241	245	249	253	258	264
269	275	281	288	295	302	309	318	331	352

Guárdelo

Estos mismos 40 datos aparecerán en todas las sesiones: primero para armar tablas (sesión 3), luego gráficos (sesión 4), después medidas (unidad 2) y al final el análisis completo (unidad 3). **Así se ve cómo cada herramienta aporta algo distinto sobre el mismo conjunto.**

La matriz de datos: cómo se guarda todo esto

Cliente	Gasto	Compras	Canal	Fidelidad
1	112	2	Tienda	Nuevo
2	127	3	App	Frecuente
3	138	1	Web	Ocasional
4	149	4	Tienda	Frecuente
...				
40	352	8	App	Frecuente

Cómo se lee

Cada **fila** es una unidad de observación (un cliente).
Cada **columna** es una variable.
Cada **celda** es un dato.
 n = número de filas; aquí, 40.

Lo que nunca debe pasar

Dos unidades en una misma fila; dos variables en una misma columna; una celda con **texto y número mezclados** ("\$127 mil aprox."); o un dato faltante escrito como **cero**, que después se promedia como si fuera un gasto real.

Esta estructura es universal: es una hoja de cálculo, una tabla de base de datos y un **data.frame** de R. **Dejar los datos así es la mitad del trabajo de cualquier análisis real.**

Ejercicio 4 — en clase (taller principal)

En grupos de 3 (20 minutos)

Su grupo asesora a la administración de la universidad, que quiere **reducir las filas en la cafetería**.

1. Formule la pregunta estadística en una sola frase.
2. Defina la población y la unidad de observación. ¿Son estudiantes, visitas o días?
3. Proponga **tres variables** y diga exactamente cómo se mediría cada una (con su unidad).
4. ¿Censo o muestra? Justifique.
5. Describa cómo tomaría los datos: quién, cuándo y dónde.
6. Enuncie **un sesgo** que podría colarse en su diseño.

Al final, dos grupos exponen y el curso busca el sesgo del otro diseño.

Ejercicio 4 — solución sugerida

Puntos 1 a 3

Pregunta: ¿cuánto espera un usuario de la cafetería y de qué depende esa espera?

Unidad: **una visita** a la cafetería (no un estudiante: un mismo estudiante puede ir varias veces).

Variables: tiempo de espera en minutos; franja horaria (mañana / mediodía / tarde); número de personas en fila al llegar.

No hay una única respuesta correcta. Lo que se evalúa es la **coherencia**: que la unidad, las variables y la forma de recolección respondan a la pregunta que se formuló en el punto 1.

Puntos 4 a 6

Muestra: un censo de todas las visitas de un semestre es inviable. Se mide una muestra de visitas.

Recolección: un observador con cronómetro, en **días y franjas distintos**, durante dos semanas.

Sesgo posible: medir solo al mediodía —la hora pico— haría ver el problema **peor** de lo que es en promedio.

Cómo se lee mal una estadística

La afirmación	Lo que falta preguntar
“El salario promedio subió 12 %”	¿Promedio o mediana? Unos pocos sueldos altos mueven el promedio
“El 80 % de los usuarios lo recomienda”	¿80 % de cuántos ? Ocho de diez no es lo mismo que 8 000 de 10 000
“Las ventas se dispararon” (con gráfico)	¿El eje vertical empieza en cero, o está cortado?
“Nueve de cada diez odontólogos lo recomiendan”	¿Quién los eligió? ¿Cuántos dijeron que no y no aparecen?
“Bajó la criminalidad un 3 %”	¿Bajaron los delitos o bajaron las denuncias ?

Las cuatro preguntas que desmontan casi cualquier cifra

¿Sobre cuántos casos? ¿Cómo se midió? ¿Comparado con qué? ¿Qué no me están mostrando?

Este curso sirve para dos cosas: producir cifras honestas y **no dejarse engañar por las ajenas**. La segunda le va a servir más veces en la vida que la primera.

Errores frecuentes en esta sesión

Error	Corrección
Confundir la unidad de observación con la institución	La unidad es aquello de lo que hay muchos : una consulta, una factura, un cliente
Llamar “dato” al tamaño de la población	$N = 1\ 200$ describe el estudio, no es una observación
Confundir la variable con el dato	La variable es “gasto mensual”; el dato es “227”
Decir “los clientes” cuando se midieron 40	Se describe la muestra : hay que nombrarla en la frase
Empezar por el cálculo	Primero pregunta, población, unidad y variables

Primer vistazo a R: la tabla de datos

Todo lo de hoy tiene un nombre en R. La **tabla de datos** es un `data.frame`: una fila por unidad de observación, una columna por variable.

```
clientes <- data.frame(
  id = 1:4,
  gasto = c(112, 127, 138, 149), # variable cuantitativa
  canal = c("Tienda", "App", "Web", "Tienda") # variable cualitativa
)
clientes
nrow(clientes) # cuantas unidades de observacion hay -> el tamaño n
ncol(clientes) # cuantas variables se midieron
```

```
  id gasto canal
1 1 112 Tienda
2 2 127 App
3 3 138 Web
4 4 149 Tienda
[1] 4
[1] 3
```

`nrow()` es el n del estudio y `ncol()` es el número de variables. En la sesión 14 volveremos sobre R con calma; por ahora basta ver que **la estructura es la misma** que dibujamos en el tablero.

Cierre de la sesión

Lo que debe quedar claro hoy

- Población es el todo (N); muestra es la parte observada (n).
- La unidad de observación es *de quién* se mide; la variable es *qué* se mide.
- Un dato es un valor concreto de una variable en una unidad.
- En una tabla: filas = unidades, columnas = variables.

Trabajo independiente para la próxima sesión

Resolver los **20 ejercicios de la lámina siguiente**; las respuestas están en la lámina posterior, para que usted mismo se corrija.

Ejercicios propuestos

1–10: una universidad con 8 000 estudiantes encuesta a 300 sobre su promedio acumulado y su programa académico.

1. ¿Cuál es la población?
2. ¿Cuál es N ?
3. ¿Cuál es la muestra?
4. ¿Cuál es n ?
5. ¿Cuál es la unidad de observación?
6. Nombre las dos variables
7. Dé un dato posible de la primera variable
8. Dé un dato posible de la segunda
9. ¿Es 8 000 un dato del estudio?
10. ¿Cuántas filas tendría la tabla de datos?
11. ¿Cuántas columnas de variables tendría?
12. ¿Población o muestra: los 40 clientes encuestados?
13. ¿Variable o constante: el nombre del supermercado?
14. ¿Qué describe la estadística descriptiva?
15. ¿Sobre quiénes se puede afirmar algo con estos datos?
16. ¿Se puede tener muestra sin población?
17. Si se encuesta a todos, ¿cómo se llama el estudio?
18. ¿Qué símbolo se usa para el tamaño poblacional?
19. ¿Y para el tamaño muestral?
20. En el conjunto del curso, ¿cuánto vale n ?

Respuestas

Autoevaluación de los ejercicios propuestos

- | | |
|--|--|
| 1. Los 8 000 estudiantes | 11. 2 |
| 2. $N = 8\,000$ | 12. Muestra |
| 3. Los 300 encuestados | 13. Constante |
| 4. $n = 300$ | 14. Lo que ya se observó |
| 5. Un estudiante | 15. Solo sobre los casos que se midieron |
| 6. Promedio acumulado y programa académico | 16. No |
| 7. Por ejemplo, 4,1 | 17. Censo |
| 8. Por ejemplo, "Administración" | 18. N |
| 9. No: es el tamaño de la población | 19. n |
| 10. 300 | 20. $n = 40$ |

Referencias

- [1] Monroy Saldívar, S. (2008). *Estadística descriptiva*. Instituto Politécnico Nacional. <https://elibro.net/es/lc/uniminuto/titulos/74722>
- [2] Ordóñez Fernández, F. F. & González Fernández, J. (2021). *Estadística descriptiva paso a paso*. Ediciones Pirámide. <https://elibro.net/es/lc/uniminuto/titulos/215449>
- [3] Llinás Solano, H. (2014). *Introducción a la estadística con aplicaciones en ciencias sociales*. Universidad del Norte. <https://elibro.net/es/lc/uniminuto/titulos/70062>

¿Preguntas?