

Estadística descriptiva

Andrés Felipe Puerta Velez

xxxxxxx@uniminuto.edu.co

CBASBL031 - CBASBL141

Sesión 3 — Semana 3 · 24 al 29 de agosto de
2026

Orden del día

1. Llamado a lista y revisión de los ejercicios propuestos
2. Repaso: la escala decide la herramienta
3. **Tema 1.5: tablas de frecuencia para datos no agrupados**
4. **Tema 1.6: tablas de frecuencia para datos agrupados**
5. Taller guiado: construcción completa de una tabla
6. Errores frecuentes y cierre

Sesión de 3 horas. Trabajaremos con un mismo conjunto de datos durante todo el bloque y lo retomaremos en las sesiones 4 y 5.

Repaso: dónde quedamos

En la sesión 2 clasificamos variables y aprendimos las cuatro escalas de medición.

La pregunta de hoy

Tengo 40 datos anotados en desorden. **¿Cómo los organizo para poder verlos?** La respuesta es la **tabla de distribución de frecuencias**, y la forma de construirla depende de si la variable es cualitativa, cuantitativa discreta o cuantitativa continua.

El hilo conductor del curso

Datos crudos → **tabla** → gráfico (sesión 4) → medidas resumen (unidad 2) → interpretación y decisión (unidad 3).

El caso que usaremos todo el semestre

Almacén Bello — datos de 40 clientes

El administrador de un almacén en Bello quiere entender a sus clientes. Toma una **muestra de 40** clientes del último mes y registra:

Variable	Cómo se registró	Tipo
Canal de compra	Tienda / App / Web / Teléfono	Cualitativa nominal
Compras del mes	Número entero de compras	Cuantitativa discreta
Gasto mensual	Miles de pesos	Cuantitativa continua

Cada tipo de variable exige una tabla distinta. Ese es exactamente el contenido de hoy.

1.5 Datos no agrupados

Los cinco tipos de frecuencia

Frecuencia	Símbolo	Qué es	Rango
Absoluta	f_i	Cuántas veces aparece la categoría o el valor	$0 \leq f_i \leq n$
Absoluta acumulada	F_i	Suma de las absolutas hasta esa fila	Termina en n
Relativa	h_i	f_i / n : proporción del total	$0 \leq h_i \leq 1$
Relativa acumulada	H_i	Suma de las relativas hasta esa fila	Termina en 1
Porcentual	$\%_i$	$h_i \times 100$	Suma 100 %

Dos controles que nunca fallan

$$\sum_{i=1}^k f_i = n \quad \sum_{i=1}^k h_i = 1$$

Si su tabla no cumple estas dos igualdades, **hay un error de conteo**.

Cuándo acumular y cuándo no

Sí tiene sentido acumular

Cuando la variable tiene **orden**: ordinal, discreta o continua.

“El 55 % gastó menos de 232 mil” es una frase con significado.

No tiene sentido acumular

Cuando la variable es **nominal**.

“El 65 % compró por tienda o app” depende del orden en que usted escribió las filas: es un número arbitrario.

Regla práctica

En una tabla de variable **nominal**, las columnas F_i y H_i se omiten. Incluirlas no es un error de cálculo, pero sí de **interpretación**, y en el examen se penaliza como tal.

Ejemplo guiado 1 — variable cualitativa

Canal de compra de los 40 clientes (datos crudos, en el orden en que se registraron):

T A W T F A W T A T W A F T W A T A W T
T W A T F A W T A T W A T W A T F A T A

T = Tienda física A = App móvil W = Web F = Teléfono

Paso 1: el conteo con palotes

Se recorre la lista **una sola vez** marcando un palote por cada dato. Nunca se cuenta categoría por categoría: eso obliga a recorrer la lista cuatro veces y multiplica los errores.

Categoría	Conteo	f_i
Tienda física		14
App móvil		12
Web		10
Teléfono		4

Ejemplo guiado 1 — la tabla terminada

Canal	f_i	h_i	$\%_i$
Tienda física	14	0,350	35,0
App móvil	12	0,300	30,0
Web	10	0,250	25,0
Teléfono	4	0,100	10,0
Total	40	1,000	100,0

El cálculo, fila por fila

$$h_1 = \frac{14}{40} = 0,350 \quad h_2 = \frac{12}{40} = 0,300$$

$$h_3 = \frac{10}{40} = 0,250 \quad h_4 = \frac{4}{40} = 0,100$$

Control: $14 + 12 + 10 + 4 = 40 \checkmark$ $0,350 + 0,300 + 0,250 + 0,100 = 1,000 \checkmark$

Cómo se lee

El 35 % de los clientes de la muestra compró en tienda física, y el canal telefónico solo representa 1 de cada 10 compras. No acumulamos porque el canal es **nominal**.

Ejercicio 1 — en clase

En parejas (10 minutos)

Una encuesta de satisfacción a 30 clientes arrojó estas respuestas:

Medio Alto Medio Bajo Alto Muy alto Medio Alto Bajo Medio
Alto Medio Muy bajo Alto Medio Muy alto Bajo Medio Alto Medio
Muy alto Bajo Alto Muy bajo Medio Alto Muy alto Bajo Medio Muy bajo

1. Construya la tabla de frecuencias con f_i , h_i y $\%_i$.
2. ¿Esta variable admite frecuencias acumuladas? Justifique y, si la respuesta es sí, agregue F_i y H_i .
3. ¿Qué porcentaje de clientes reportó satisfacción *media o inferior*?

Ejercicio 1 — solución

Satisfacción	f_i	F_i	h_i	H_i	$\%_i$
Muy bajo	3	3	0,100	0,100	10,0
Bajo	5	8	0,167	0,267	16,7
Medio	9	17	0,300	0,567	30,0
Alto	8	25	0,267	0,833	26,7
Muy alto	5	30	0,167	1,000	16,7
Total	30		1,000		100,0

Puntos 2 y 3

Sí admite acumuladas: la satisfacción es **ordinal**, sus categorías tienen un orden natural de menor a mayor. Por eso las filas deben escribirse en ese orden, no alfabéticamente.

Media o inferior: $H_3 = 0,567 \Rightarrow 56,7\%$ de los clientes. Se lee directamente de la columna acumulada, sin volver a sumar.

Ejemplo guiado 2 — cuantitativa discreta

Número de compras en el mes de 25 clientes:

2 3 1 0 2 4 3 2 1 5 2 3 6 1 2 4 0 3 8 2 5 1 6 4 3

Regla de decisión

Una variable discreta se deja **sin agrupar** cuando toma pocos valores distintos (guía práctica: **menos de 15**). Aquí toma 8 valores distintos: cada uno es una fila.

Ordenar los datos de menor a mayor antes de contar reduce los errores casi a cero. Es el primer paso siempre.

Ejemplo guiado 2 — la tabla terminada

x_i	f_i	F_i	h_i	H_i	$\%_i$
0	2	2	0,08	0,08	8
1	4	6	0,16	0,24	16
2	6	12	0,24	0,48	24
3	5	17	0,20	0,68	20
4	3	20	0,12	0,80	12
5	2	22	0,08	0,88	8
6	2	24	0,08	0,96	8
8	1	25	0,04	1,00	4
Tot.	25		1,00		100

Dos lecturas

$F_3 = 17$: **17 clientes hicieron 3 compras o menos.**

$H_4 = 0,80$: el 80 % hizo 4 compras o menos.

La trampa

El valor 7 no aparece porque **nadie** hizo 7 compras. Se puede incluir la fila con $f_i = 0$ u omitirla, pero jamás se salta un valor que sí fue observado.

Ejercicio 2 — en clase

Individual (10 minutos)

Número de quejas recibidas por día durante 20 días:

1 3 0 2 1 4 2 1 0 3 2 1 5 2 0 1 3 2 4 1

1. Construya la tabla completa $(x_i, f_i, F_i, h_i, H_i)$.
2. ¿En cuántos días hubo *a lo sumo* 2 quejas?
3. ¿Qué porcentaje de días tuvo *más* de 3 quejas?
4. Verifique los dos controles: $\sum f_i = n$ y $\sum h_i = 1$.

Ejercicio 2 — solución

x_i	f_i	F_i	h_i	H_i
0	3	3	0,15	0,15
1	6	9	0,30	0,45
2	5	14	0,25	0,70
3	3	17	0,15	0,85
4	2	19	0,10	0,95
5	1	20	0,05	1,00
Tot.	20		1,00	

Respuestas

2. “A lo sumo 2” es $F_3 = 14$ días.

3. “Más de 3” es el complemento:
 $1 - H_4 = 1 - 0,85 = 0,15 \Rightarrow 15\%$.

4. $3 + 6 + 5 + 3 + 2 + 1 = 20 \checkmark$
 $0,15 + 0,30 + 0,25 + 0,15 + 0,10 + 0,05 = 1,00 \checkmark$

El error de vocabulario más común

“A lo sumo 3” incluye el 3 (F_i directo). “Menos de 3” no lo incluye (hay que usar F_{i-1}). “Más de 3” es $1 - H_i$. Léalo dos veces antes de responder.



UNIMINUTO
Corporación Universitaria Minuto de Dios
Educación de calidad al alcance de todos
Sede Arica - Chile
Vigilante de Calidad

VERY GOOD



1.6 Datos agrupados

¿Por qué agrupar?

Gasto mensual (miles de pesos) de los 40 clientes, ya ordenado:

112	127	138	149	153	158	165	171	178	184
190	195	199	203	208	212	215	219	222	226
229	231	234	238	241	245	249	253	258	264
269	275	281	288	295	302	309	318	331	352

El problema

Si hiciéramos una fila por valor tendríamos **40 filas con frecuencia 1** cada una: una tabla tan larga como la lista original y que no resume nada. Cuando la variable es continua, casi ningún valor se repite.

La solución es **agrupar en intervalos de clase**: sacrificamos un poco de detalle a cambio de poder ver la forma de la distribución.

El procedimiento en seis pasos

1. **Ordenar** los datos y localizar el mínimo y el máximo.

2. Calcular el **rango**: $R = x_{\max} - x_{\min}$

3. Decidir el **número de clases** k (regla de Sturges):

$$k = 1 + 3,322 \cdot \log_{10}(n)$$

4. Calcular la **amplitud** de clase: $A = R/k$, redondeando *siempre hacia arriba*.

5. Construir los **intervalos** desde $x_{\min}$, sumando A .

6. **Contar** cuántos datos caen en cada intervalo y completar las columnas de frecuencia.

Sobre Sturges

Es una **guía, no una ley**. Da un k razonable para que la tabla no sea ni demasiado gruesa ni demasiado fina. En la práctica se acepta cualquier k entre 5 y 15, y muchas veces se ajusta para que la amplitud quede en un número redondo.

Paso a paso con el caso Almacén Bello

Pasos 1 a 4

1. $x_{\min} = 112$, $x_{\max} = 352$, $n = 40$

2. $R = 352 - 112 = 240$

3. $k = 1 + 3,322 \cdot \log_{10}(40)$

$$\log_{10}(40) = 1,6021$$

$$k = 1 + 3,322(1,6021) = 1 + 5,322 = 6,32$$

$$\Rightarrow k = 6$$

4. $A = \frac{R}{k} = \frac{240}{6} = 40$

Paso 5: los intervalos

Se arranca en 112 y se suma 40 seis veces:

Clase 1 [112, 152)

Clase 2 [152, 192)

Clase 3 [192, 232)

Clase 4 [232, 272)

Clase 5 [272, 312)

Clase 6 [312, 352]

Ojo con la última

Los intervalos son **cerrados por izquierda y abiertos por derecha**, excepto el último, que se cierra para que el máximo quede dentro.

Marca de clase y límites reales

Marca de clase x_i

Es el punto medio del intervalo. **Representa** a todos los datos de esa clase en los cálculos de la unidad 2.

$$x_i = \frac{L_{\text{inf}} + L_{\text{sup}}}{2}$$

Ejemplo clase 3:

$$x_3 = \frac{192 + 232}{2} = 212$$

Amplitud y verificación

$$A = L_{\text{sup}} - L_{\text{inf}} = 232 - 192 = 40$$

Todas las clases deben tener la **misma amplitud**. Si no, los gráficos y las medidas se distorsionan.

Verificación global:

$$k \cdot A = 6 \times 40 = 240 \geq R = 240 \checkmark$$

Lo que se pierde al agrupar

Al agrupar dejamos de saber que el cliente más gastador gastó 352. Solo sabemos que **alguien cayó en la clase** [312, 352]. Por eso los cálculos con datos agrupados son **aproximados**.

Paso 6: la tabla terminada

Clase (gasto)	x_i	f_i	F_i	h_i	H_i	$\%_i$	$\% \text{ ac.}$
[112, 152)	132	4	4	0,100	0,100	10,0	10,0
[152, 192)	172	7	11	0,175	0,275	17,5	27,5
[192, 232)	212	11	22	0,275	0,550	27,5	55,0
[232, 272)	252	9	31	0,225	0,775	22,5	77,5
[272, 312)	292	6	37	0,150	0,925	15,0	92,5
[312, 352]	332	3	40	0,075	1,000	7,5	100,0
Total		40		1,000		100,0	

Cómo se obtuvo la fila 3, en detalle

Datos en [192, 232): 195, 199, 203, 208, 212, 215, 219, 222, 226, 229, 231 $\Rightarrow f_3 = 11$.

$$F_3 = 4 + 7 + 11 = 22 \quad h_3 = \frac{11}{40} = 0,275 \quad H_3 = 0,100 + 0,175 + 0,275 = 0,550$$

Cómo se lee esta tabla

Cuatro frases que el administrador puede usar

- La clase **más frecuente** es $[192, 232)$: **27,5 % de los clientes** gasta entre 192 y 232 mil pesos al mes.
- $H_3 = 0,550$: el **55 %** gasta menos de 232 mil.
- $1 - H_4 = 1 - 0,775 = 0,225$: el **22,5 %** gasta 272 mil o más. Ese es el segmento premium.
- $f_1 = 4$: solo 4 clientes están por debajo de 152 mil. El almacén casi no tiene clientes de gasto bajo.

Lo que una tabla no puede decir

Estas frases describen a los **40 clientes de la muestra**. Afirmar que “el 55 % de todos los clientes del almacén gasta menos de 232 mil” ya sería hablar de **clientes que nunca se midieron**. En este curso describimos lo observado; nos detenemos ahí.

Ejercicio 3 — en clase (taller principal)

En grupos de 3 (20 minutos)

Tiempo de espera en caja, en minutos, de 30 clientes:

4	5	7	8	9	10	11	12	13	13	14	15	16	17	17
18	19	20	21	22	23	24	25	26	27	28	29	30	32	34

1. Calcule R , k (Sturges) y A . Muestre el cálculo.
2. Construya los intervalos y la tabla completa con marca de clase.
3. ¿Qué porcentaje de clientes esperó menos de 19 minutos?
4. ¿Qué porcentaje esperó 24 minutos o más?
5. El gerente promete “atención en menos de 15 minutos”. ¿Qué proporción de clientes recibe lo prometido?

Ejercicio 3 — solución (pasos 1 y 2)

Los cálculos previos

$$R = 34 - 4 = 30$$

$$k = 1 + 3,322 \cdot \log_{10}(30)$$

$$\log_{10}(30) = 1,4771$$

$$k = 1 + 4,907 = 5,91 \Rightarrow k = 6$$

$$A = \frac{30}{6} = 5$$

$$\text{Control: } 4 + 6 + 6 + 5 + 5 + 4 = 30 \checkmark \quad k \cdot A = 6 \times 5 = 30 \geq R \checkmark$$

Clase	x_i	f_i	F_i	h_i	H_i
[4, 9)	6,5	4	4	0,133	0,133
[9, 14)	11,5	6	10	0,200	0,333
[14, 19)	16,5	6	16	0,200	0,533
[19, 24)	21,5	5	21	0,167	0,700
[24, 29)	26,5	5	26	0,167	0,867
[29, 34]	31,5	4	30	0,133	1,000
Tot.		30		1,000	

Ejercicio 3 — solución (interpretación)

Puntos 3 y 4

3. “Menos de 19” coincide con el límite superior de la clase 3: $H_3 = 0,533 \Rightarrow 53,3 \%$.
4. “24 o más” es el complemento de “menos de 24”, y 24 es el límite superior de la clase 4:
 $1 - H_4 = 1 - 0,700 = 0,300 \Rightarrow 30,0 \%$.

Punto 5: la pregunta difícil

“Menos de 15 minutos” **no coincide** con ningún límite de clase: cae dentro de [14, 19). Con la tabla agrupada solo podemos **aproximar** suponiendo que los 6 datos de esa clase se reparten de forma uniforme:

$$H(15) \approx 0,333 + 0,200 \cdot \frac{15 - 14}{5} = 0,333 + 0,040 = 0,373 \Rightarrow 37,3 \%$$

Con los datos **originales** el valor exacto es $11/30 = 36,7 \%$. La diferencia es **el costo de haber agrupado**.

Errores frecuentes en el examen

Error	Corrección
Intervalos que se solapan: $[112, 152]$ y $[152, 192]$	Un dato debe caer en una sola clase: $[112, 152)$, $[152, 192)$
Clases de amplitud distinta	Todas iguales, salvo instrucción explícita en contra
Acumular frecuencias en variable nominal	Solo se acumula si hay orden
Redondear A hacia abajo	Siempre hacia arriba: si no, el máximo queda fuera de la tabla
Reportar h_i y $\%_i$ como si fueran cosas distintas	$\%_i = h_i \times 100$; se elige una de las dos
Olvidar la fila de totales	Es la que permite verificar el trabajo

La misma tabla, en R

En la sesión 14 trabajaremos R a fondo. Por ahora, vea que **toda la tabla de hoy cabe en cinco líneas**.

```
canal <- factor(canal) # cualitativa nominal
table(canal) # frecuencias absolutas
round(prop.table(table(canal)) * 100, 1) # porcentajes

limites <- seq(112, 352, by = 40) # los limites de clase
clases <- cut(gasto, breaks = limites, right = FALSE, include.lowest = TRUE)
fi <- table(clases); Fi <- cumsum(fi); hi <- prop.table(fi); Hi <- cumsum(hi)
fi
```

```
clases
[112,152) [152,192) [192,232) [232,272) [272,312) [312,352]
  4  7 11  9  6  3
```

Los dos argumentos que importan

`right = FALSE` produce intervalos $[a, b)$, la convención del curso; `include.lowest = TRUE` cierra el último para que el máximo entre. Sin ellos R usa $(a, b]$ y la tabla no coincide con la de clase.

Cierre de la sesión

Lo que debe quedar claro hoy

- Cinco frecuencias: f_i , F_i , h_i , H_i y $\%i$; y dos controles que siempre se verifican.
- Cualitativa y discreta con pocos valores: **una fila por categoría o valor**, sin agrupar.
- Continua o discreta con muchos valores: **intervalos de clase** mediante R , Sturges, A y marca de clase.
- Solo se acumula cuando la variable tiene orden.
- Agrupar resume, pero **pierde información**: los resultados pasan a ser aproximados.

Trabajo independiente

Resolver los 20 ejercicios de la lámina siguiente y **traer la tabla del caso Almacén Bello impresa o en el cuaderno**: en la sesión 4 la convertimos en histograma, polígono y ojiva.

Ejercicios propuestos

1–8: conceptos y lectura de tablas. 9–14: cálculo de R , k y A . 15–20: construcción e interpretación.

- ¿Qué significa F_i ?
- ¿Qué significa H_i ?
- ¿Cuánto suma siempre $\sum h_i$?
- ¿Se acumula en una variable nominal?
¿Por qué?
- Si $n = 50$ y $f_3 = 12$, ¿cuánto vale h_3 ?
- Si $H_4 = 0,62$ y $h_5 = 0,18$, ¿cuánto vale H_5 ?
- Si $F_5 = 38$ y $F_4 = 29$, ¿cuánto vale f_5 ?
- ¿Qué es la marca de clase y para qué sirve?
- $n = 60$: calcule k con Sturges.
- $n = 100$: calcule k con Sturges.
- $x_{\min} = 18$, $x_{\max} = 93$: calcule R .
- Con $R = 75$ y $k = 7$: calcule A .
- Clase $[45, 60)$: marca de clase y amplitud.
- ¿Por qué A se redondea hacia arriba?
- Con la tabla del Almacén Bello: ¿qué % gasta menos de 192?
- ¿Qué % gasta entre 192 y 272?
- ¿Cuántos clientes gastan 272 o más?
- ¿Cuál es la clase modal y qué significa?
- Si el gerente sube el corte premium a 312, ¿a cuántos clientes afecta?
- ¿Por qué agrupar hace que los cálculos sean aproximados?

Respuestas

Autoevaluación de los ejercicios propuestos

1. Datos con valor menor o igual al de esa fila
2. Proporción acumulada hasta esa fila
3. 1 (o 100 % en porcentaje)
4. No: sin orden, la acumulada es arbitraria
5. $12/50 = 0,24$
6. $0,62 + 0,18 = 0,80$
7. $38 - 29 = 9$
8. Punto medio de la clase; representa a la clase
9. $1 + 3,322(1,7782) = 6,91 \Rightarrow 7$
10. $1 + 3,322(2) = 7,64 \Rightarrow 8$
11. $R = 93 - 18 = 75$
12. $A = 75/7 = 10,71 \Rightarrow 11$
13. $x_i = 52,5$; $A = 15$
14. Para que $k \cdot A \geq R$ y el máximo entre en la tabla
15. $H_2 = 27,5 \%$
16. $h_3 + h_4 = 0,275 + 0,225 = 50,0 \%$
17. $6 + 3 = 9$ clientes
18. $[192, 232)$: el gasto más común de la muestra
19. A 3 clientes (f_6), el 7,5 %
20. Porque la marca de clase reemplaza a los datos reales

Referencias

- [1] Monroy Saldívar, S. (2008). *Estadística descriptiva*. Instituto Politécnico Nacional. <https://elibro.net/es/lc/uniminuto/titulos/74722>
- [2] Ordóñez Fernández, F. F. & González Fernández, J. (2021). *Estadística descriptiva paso a paso*. Ediciones Pirámide. <https://elibro.net/es/lc/uniminuto/titulos/215449>
- [3] Llinás Solano, H. (2014). *Introducción a la estadística con aplicaciones en ciencias sociales*. Universidad del Norte. <https://elibro.net/es/lc/uniminuto/titulos/70062>

¿Preguntas?