

Estadística descriptiva

Andrés Felipe Puerta Velez

xxxxxxx@uniminuto.edu.co

CBASBL031 - CBASBL141

Sesión 14 — Semana 14 · 9 al 14 de noviembre de 2026

Orden del día

1. Llamado a lista y revisión de los ejercicios propuestos
2. **Tema 3.3: un caso completo, de los datos crudos a la tabla**
3. Primeros pasos en **R**: objetos, vectores y `data.frame`
4. **Tema 3.4: medidas, tablas y gráficos con R base**
5. Comparación de grupos y errores frecuentes
6. Taller en computador y cierre

Sesión de 3 horas. Traiga computador si puede; si no, se trabaja en parejas. Usamos **R base**: nada de lo que veremos hoy exige instalar paquetes adicionales.

Por qué R y no una hoja de cálculo

Lo que gana

- El análisis queda **escrito**: se puede repetir, revisar y corregir.
- Si cambian los datos, se vuelve a correr el mismo guion.
- Otra persona puede **reproducir** exactamente su resultado.
- Es gratuito y es el estándar en analítica.

Lo que cuesta

- Hay que escribir, no hacer clic.
- Los errores de sintaxis detienen todo (mayúsculas, comas, paréntesis).
- La curva de entrada es de unas pocas horas.

La razón de fondo

En una hoja de cálculo, el análisis **está en los clics que usted hizo** y nadie los ve. En R, el análisis **es el archivo**: cualquiera puede leerlo, auditarlo y volverlo a correr dentro de un año.

Lo mínimo para empezar

Cuatro ideas

- `<-` guarda un valor en un objeto.
- `c()` arma un vector (una columna de datos).
- Una **función** se llama con paréntesis:
`mean(x)`.
- `#` inicia un comentario: R lo ignora.

```
# Un objeto con tres numeros  
x <- c(4, 7, 10)  
mean(x) # promedio  
length(x) # cuantos datos hay
```

```
[1] 7  
[1] 3
```

Dónde se escribe

En RStudio: el **Script** (arriba a la izquierda) se guarda; la **Consola** (abajo) solo ejecuta. **Escriba siempre en el script** y ejecute con Ctrl+Enter.

3.3 Caso completo: Ferretería El Tornillo

Los datos crudos

Valor de compra, en miles de pesos, de 50 clientes de octubre (ya ordenados):

10	13	16	19	21	22	23	24	25	26	27	28	28	29	29
30	31	32	33	34	35	35	36	36	37	38	38	39	39	41
42	43	44	45	46	47	48	49	51	53	54	56	57	58	61
					63	66	68	72	80					

Antes de calcular nada

Contar. $n = 50$. **Mirar los extremos.** $x_{\min} = 10$, $x_{\max} = 80$. **Buscar rarezas.** ¿Hay ceros, negativos, datos faltantes o valores imposibles? Aquí no, pero ese chequeo es obligatorio en datos reales.

Paso 1 — clasificar las variables

Variable	Registro	Tipo y escala	Cómo se guarda en R
Valor de compra	Miles de pesos	Continua, razón	<code>numeric</code>
Zona del cliente	Norte / Centro / Sur	Nominal	<code>factor</code>
Forma de pago	Efectivo / Tarjeta / Crédito	Nominal	<code>factor</code>
Nivel de fidelidad	Nuevo / Ocasional / Fre- cuente	Ordinal	<code>factor(ordered = TRUE)</code>

Por qué importa el tipo en R

Si una variable cualitativa queda como `character`, R la ordena **alfabéticamente**. Si se declara `factor` con niveles en el orden correcto, las tablas y los gráficos respetan el orden de la escala. Es la traducción exacta de lo que vimos en la sesión 2.

Paso 2 — cargar los datos en R

```
# Opcion A: escribir el vector directamente
valor <- c(10,13,16,19,21,22,23,24,25,26,27,28,28,29,29,
          30,31,32,33,34,35,35,36,36,37,38,38,39,39,41,
          42,43,44,45,46,47,48,49,51,53,54,56,57,58,61,
          63,66,68,72,80)
```

```
# Opcion B: leer un archivo guardado como CSV
# datos <- read.csv("tornillo.csv")
# valor <- datos$valor
```

```
length(valor) # verificar que son 50
summary(valor) # primer vistazo
```

```
[1] 50
   Min. 1st Qu. Median Mean 3rd Qu. Max.
 10.00 28.25 37.50 39.54 48.75 80.00
```

`summary()` es el primer comando que se corre siempre: en una línea entrega el resumen de cinco números y la media.

3.4 Medidas, tablas y gráficos con R base

Las funciones que reemplazan todo el cálculo a mano

Medida	Función en R	Resultado
Cantidad de datos	<code>length(valor)</code>	50
Media	<code>mean(valor)</code>	39,54
Mediana	<code>median(valor)</code>	37,50
Mínimo y máximo	<code>min(valor)</code> <code>max(valor)</code>	10 y 80
Rango	<code>diff(range(valor))</code>	70
Cuartiles	<code>quantile(valor)</code>	28,25 y 48,75
Percentil 90	<code>quantile(valor, 0.90)</code>	61,20
Rango intercuartílico	<code>IQR(valor)</code>	20,50
Varianza (muestra)	<code>var(valor)</code>	247,15
Desviación (muestra)	<code>sd(valor)</code>	15,72
Coefficiente de variación	<code>sd(valor)/mean(valor)*100</code>	39,76 %
Resumen completo	<code>summary(valor)</code>	los cinco números y la media

R **no** trae una función de moda ni de asimetría en la instalación base: las construimos en las dos láminas siguientes. `var()` y `sd()` dividen entre $n - 1$, es decir, son las de **muestra**.

Moda, asimetría y curtosis a mano en R

```
# Moda: el valor mas repetido
tab <- table(valor)
names(tab)[tab == max(tab)]

# Asimetria de Pearson (mediana)
As2 <- 3 * (mean(valor) - median(valor)) / sd(valor)

# Fisher: g1 y g2 (exceso de curtosis), con sigma poblacional
n <- length(valor)
mu <- mean(valor)
sg <- sqrt(sum((valor - mu)^2) / n)
g1 <- sum((valor - mu)^3) / n / sg^3
g2 <- sum((valor - mu)^4) / n / sg^4 - 3
round(c(As2 = As2, g1 = g1, g2 = g2), 3)
```

```
[1] "28" "29" "35" "36" "38" "39"
      As2 g1 g2
0.389 0.465 -0.242
```

Seis valores empatados con dos repeticiones: en datos continuos la moda **casi nunca es informativa**, y por eso se agrupa.

La tabla de frecuencias con `cut()` y `table()`

```
limites <- seq(10, 80, by = 10) # 10,20,...,80
clases <- cut(valor, breaks = limites,
              right = FALSE, # intervalos [a, b)
              include.lowest = TRUE) # el 80 entra en la ultima
fi <- table(clases)
fi
```

```
clases
[10,20) [20,30) [30,40) [40,50) [50,60) [60,70) [70,80]
      4  11  14   9   6   4   2
```

Los dos argumentos que hay que entender

`right = FALSE` produce intervalos **cerrados por izquierda y abiertos por derecha**, que es la convención del curso. `include.lowest = TRUE` cierra el **último** intervalo para que el máximo no quede fuera. Sin estos dos argumentos, R usa $(a, b]$ y la tabla no coincide con la que hicimos a mano.

La tabla completa, con todas las frecuencias

```
Fi <- cumsum(fi) # absoluta acumulada
hi <- prop.table(fi) # relativa
Hi <- cumsum(hi) # relativa acumulada
xi <- head(limites, -1) + 5 # marca de clase

tabla <- data.frame(xi, fi = as.vector(fi), Fi = as.vector(Fi),
                    hi = round(as.vector(hi), 3),
                    Hi = round(as.vector(Hi), 3))

tabla
```

xi	fi	Fi	hi	Hi
1	15	4	0.080	0.080
2	25	11	0.220	0.300
3	35	14	0.280	0.580
4	45	9	0.180	0.760
5	55	6	0.120	0.880
6	65	4	0.080	0.960
7	75	2	0.040	1.000

Es **exactamente** la tabla de la sesión 11, pero en seis líneas y sin una sola cuenta a mano.

Variables cualitativas: factor y table

```
zona <- factor(zona) # nominal
fidelidad <- factor(fidelidad,
                    levels = c("Nuevo", "Ocasional", "Frecuente"),
                    ordered = TRUE) # ordinal: el orden manda

table(zona) # frecuencias absolutas
round(prop.table(table(zona)) * 100, 1) # porcentajes
cumsum(table(fidelidad)) # acumulada: solo si es ordinal
```

El detalle que decide todo

Al declarar `levels = c("Nuevo", "Ocasional", "Frecuente")` le estamos diciendo a R cuál es el **orden natural** de la escala. Sin eso, R ordenaría alfabéticamente —Frecuente, Nuevo, Ocasional— y tanto la acumulada como el gráfico de barras quedarían sin sentido.

Para cruzar dos variables cualitativas: `table(zona, pago)` devuelve la tabla de doble entrada, y `addmargins()` le agrega los totales.

Los gráficos, uno por línea

```
# Cualitativa: barras separadas y circular
barplot(table(zona), col = "steelblue",
        main = "Clientes por zona", ylab = "Frecuencia")
pie(table(zona), main = "Participación por zona")

# Cuantitativa: histograma con NUESTROS límites de clase
hist(valor, breaks = limites, right = FALSE,
     main = "Valor de compra de 50 clientes",
     xlab = "Miles de pesos", ylab = "Frecuencia", col = "steelblue")

# Polígono de frecuencias sobre el histograma
lines(c(5, xi, 85), c(0, as.vector(fi), 0), type = "b", col = "tomato")

# Ojiva: acumulada sobre los límites superiores
plot(limites, c(0, Fi), type = "b",
     main = "Ojiva", xlab = "Miles de pesos", ylab = "Fi acumulada")

# Diagrama de caja
boxplot(valor, horizontal = TRUE, col = "steelblue",
       main = "Valor de compra", xlab = "Miles de pesos")
```

`hist()` con `breaks = limites` obliga a R a usar las clases del curso; sin ese argumento, R elige las suyas con la regla de Sturges y el gráfico no coincide con la tabla.

Comparar grupos en dos líneas

```
# Una medida por grupo
tapply(valor, zona, mean)
tapply(valor, zona, median)
round(tapply(valor, zona, sd) / tapply(valor, zona, mean) * 100, 1) # CV

# Cajas paralelas: la formula se lee "valor SEGUN zona"
boxplot(valor ~ zona, col = "steelblue",
        main = "Valor de compra por zona",
        xlab = "Zona", ylab = "Miles de pesos")

# Los cinco numeros y los atipicos que usa el grafico
boxplot.stats(valor)$stats # bigote inf, Q1, mediana, Q3, bigote sup
boxplot.stats(valor)$out  # valores atipicos
```

```
[1] 10 28 37.5 49 80
numeric(0)
```

`numeric(0)` significa "ningún valor atípico", igual que concluimos a mano en la sesión 11. Esta lámina es toda la comparación de grupos de la sesión 13, hecha en R.

¿Por qué R no da exactamente lo mismo que a mano?

Medida	A mano (agrupado)	R (datos crudos)	Por qué difieren
Media	39,40	39,54	La marca de clase reemplaza al dato real
Mediana	37,14	37,50	La fórmula agrupada interpola dentro de la clase
Moda	33,75	varias	Czuber estima; <code>table()</code> da los valores repetidos
Q_1	27,73	28,25	Distinta convención de posición
Q_3	49,44	48,75	Distinta convención de posición
s	15,54	15,72	Agrupamiento

Cuál está bien

Los dos. El cálculo agrupado es una **aproximación** que se usa cuando solo se dispone de la tabla; R usa los datos originales y es más exacto. Lo que **nunca** se hace es mezclarlos en un mismo informe sin decir cuál se usó.

`quantile()` tiene **nueve** métodos distintos (`type = 1..9`); el predeterminado es el 7. `fivenum()` y `boxplot()` usan otra convención (bisagras de Tukey), y por eso `quantile(valor)` da 28,25 mientras `boxplot.stats()` da 28. Diferencias así son normales y no son un error.

Errores frecuentes en R

Error	Qué pasa y cómo se corrige
Error: <code>object 'valor' not found</code>	No se ejecutó la línea que lo crea, o está mal escrito. R distingue mayúsculas: <code>Valor</code> $\neq$ <code>valor</code>
La consola muestra <code>+</code> y no responde	Falta cerrar un paréntesis o una comilla. Pulse Esc
<code>mean()</code> devuelve <code>NA</code>	Hay datos faltantes: use <code>mean(valor, na.rm = TRUE)</code>
La tabla no coincide con la de clase	Falta <code>right = FALSE</code> o <code>include.lowest = TRUE</code> en <code>cut()</code>
El gráfico de barras sale desordenado	La variable es <code>character</code> : conviértala en <code>factor</code> con <code>levels</code>
<code>sd()</code> distinto al esperado	<code>sd()</code> es de muestra ($n - 1$); la poblacional se calcula a mano

Control final infalible: `sum(fi)` debe dar **exactamente** `length(valor)`. Si no coincide, hay datos fuera de los límites de `cut()`.

Taller en computador — parte 1

En parejas (30 minutos)

Abra RStudio, cree un script nuevo y guárdelo como `tornillo.R`. Todo debe quedar **escrito en el script**, no en la consola.

1. Cargue los 50 datos con `c()` y verifique `length()`.
2. Corra `summary()` e interprete su salida en una frase.
3. Calcule media, mediana, cuartiles, `IQR`, `var`, `sd` y el `CV`.
4. Construya `clases` con `cut()` y obtenga `fi`.
5. Agregue `Fi`, `hi`, `Hi` y `xi`, y arme el `data.frame`.
6. Verifique que `sum(fi) == 50` y que el último `Hi` es 1.
7. Compare sus resultados con los calculados a mano en la sesión 11 y explique cada diferencia.

Taller en computador — parte 2

En parejas (25 minutos)

1. Haga el **histograma** con `breaks = limites` y `right = FALSE`.
2. Superponga el **polígono** con `lines()`, cerrado sobre el eje.
3. Dibuje la **ojiva** con `plot()`.
4. Dibuje el **diagrama de caja** y compárelo con el que hizo a mano en la sesión 11.
5. Cree una variable `zona` con 50 valores inventados (Norte/Centro/Sur), conviértala en `factor` y haga `table(zona)` y su gráfico de barras.
6. Calcule `tapply(valor, zona, mean)` y haga `boxplot(valor ~ zona)`. Escriba **dos frases** de interpretación.

Al cierre, dos parejas proyectan su script y el curso revisa títulos, ejes y coherencia de los gráficos.

El script completo, para guardar

```
valor <- c(10,13,16,19,21,22,23,24,25,26,27,28,28,29,29,30,31,32,33,34,
          35,35,36,36,37,38,38,39,39,41,42,43,44,45,46,47,48,49,51,53,
          54,56,57,58,61,63,66,68,72,80)
limites <- seq(10, 80, by = 10)
clases <- cut(valor, breaks = limites, right = FALSE, include.lowest = TRUE)

fi <- table(clases); Fi <- cumsum(fi)
hi <- prop.table(fi); Hi <- cumsum(hi)
xi <- head(limites, -1) + 5
tabla <- data.frame(xi, fi = as.vector(fi), Fi = as.vector(Fi),
                    hi = round(as.vector(hi), 3), Hi = round(as.vector(Hi), 3))

medidas <- c(n = length(valor), media = mean(valor), mediana = median(valor),
             Q1 = quantile(valor, .25), Q3 = quantile(valor, .75),
             IQR = IQR(valor), s = sd(valor),
             CV = sd(valor) / mean(valor) * 100)

hist(valor, breaks = limites, right = FALSE, col = "steelblue",
     main = "Valor de compra", xlab = "Miles de pesos")
boxplot(valor, horizontal = TRUE, col = "steelblue")
```

Diecisiete líneas reemplazan tres sesiones de cálculo a mano. **Pero solo tienen sentido si usted sabe qué está calculando:** esa es la diferencia entre las sesiones 3 a 11 y esta.

Lista de verificación antes de entregar

Script y cálculos

- `length(valor)` coincide con el n declarado
- `sum(fi) = length(valor)` y el último H_i es 1
- Se usó `sd()` sabiendo que es de muestra
- Ninguna cifra está digitada a mano en el informe
- El script corre completo **de arriba abajo** sin errores

Tablas y gráficos

- Cada tabla y figura está numerada y titulada
- `main`, `xlab` y `ylab` escritos con unidades
- El histograma usa `breaks = limites`
- El polígono está cerrado sobre el eje
- Cada figura se menciona en el texto

La prueba definitiva

Cierre R, ábralo de nuevo y corra el script **desde la primera línea**. Si todo se reproduce sin tocar nada, el trabajo está bien hecho.

Cierre de la sesión

Lo que debe quedar claro hoy

- En R el análisis **es un archivo**: se guarda, se audita y se repite.
- `summary()`, `mean()`, `median()`, `quantile()`, `IQR()`, `var()` y `sd()` cubren toda la Unidad 2.
- `cut()` + `table()` + `cumsum()` + `prop.table()` construyen la tabla de la Unidad 1.
- `hist()`, `barplot()`, `plot()` y `boxplot()` dan todos los gráficos del curso.
- Los resultados con datos crudos **difieren un poco** de los agrupados, y hay que declarar cuál se usó.
- R no piensa: el criterio sobre qué medida y qué gráfico usar sigue siendo suyo.

Trabajo independiente

Terminar el script del taller. En la sesión 15 trabajamos la **coherencia entre análisis y conclusiones** y la sustentación oral, y hacemos el repaso para el Examen 3.

Ejercicios propuestos

1–8: funciones. 9–14: tablas y gráficos. 15–20: criterio y verificación.

1. Función para la media de valor
2. Función para la mediana
3. Función para el tercer cuartil
4. Función para el percentil 40
5. ¿`sd()` es de muestra o de población?
6. ¿Cómo se calcula el CV en R?
7. Función para contar los clientes de la zona Norte
8. ¿Qué hace `summary(valor)`?
9. ¿Qué argumentos de `cut()` dan intervalos $[a, b)$?
10. ¿Cómo se obtiene `hi` a partir de `hi`?

11. ¿Cómo se fuerza el histograma a usar nuestras clases?
12. ¿Cómo se comparan medias por zona en una línea?
13. ¿Qué gráfico usa para zona? ¿Y para valor?
14. ¿Qué devuelve `boxplot.stats(valor)$out`?
15. ¿Por qué `mean(valor)` no coincide con la media agrupada?
16. ¿Cuál de las dos reportaría y por qué?
17. ¿Qué significa que `mean()` devuelva `NA`?
18. ¿Por qué `quantile()` y `summary()` difieren?
19. ¿Por qué una cualitativa debe ser `factor` y no `character`?
20. ¿Cuál es la prueba de que el script está bien hecho?

Respuestas

Autoevaluación de los ejercicios propuestos

```
1. mean(valor)
2. median(valor)
3. quantile(valor, 0.75)
4. quantile(valor, 0.40)
5. De muestra: divide entre  $n - 1$ 
6.  $sd(valor) / mean(valor) * 100$ 
7.  $sum(zona == "Norte") / nrow(zona)$ 
8. Mínimo,  $Q_1$ , mediana, media,  $Q_3$  y máximo
9. right = FALSE e include.lowest = TRUE
10. cumsum(hi)
```

```
11. hist(valor, breaks = limites, right = FALSE)
12. tapply(valor, zona, mean)
13. barplot() e hist(), respectivamente
14. Los valores atípicos: numeric(0) si no hay
15. Porque la agrupada usa marcas de clase
16. a de datos crudos, si se tienen; y se declara
17. Que hay datos faltantes: use na.rm = TRUE
18. Usan convenciones distintas de cuartil
19. Para fijar los niveles y su orden
20. Que corre completo desde cero en una sesión nueva
```

Referencias

- [1] Monroy Saldívar, S. (2008). *Estadística descriptiva*. Instituto Politécnico Nacional.
<https://elibro.net/es/lc/uniminuto/titulos/74722>
- [2] Ordóñez Fernández, F. F. & González Fernández, J. (2021). *Estadística descriptiva paso a paso*. Ediciones Pirámide. <https://elibro.net/es/lc/uniminuto/titulos/215449>
- [3] Llinás Solano, H. (2014). *Introducción a la estadística con aplicaciones en ciencias sociales*. Universidad del Norte. <https://elibro.net/es/lc/uniminuto/titulos/70062>
- [4] R Core Team (2025). *An Introduction to R*.
<https://cran.r-project.org/doc/manuals/R-intro.pdf>

¿Preguntas?