

Estadística General

Contenido

Medidas de tendencia central

Medidas de posición

Medidas de dispersión

Box-plot

Medidas de tendencia central: introducción

Una tendencia humana natural es hacer comparaciones con el "promedio". Por ejemplo, un estudiante que obtiene un 40 % en un examen estará contento con el resultado si la puntuación media de la clase es del 25 %. Si la puntuación media de la clase es del 90 %, el estudiante puede no sentirse feliz aunque haya obtenido un 70 % correcto. A las funciones estadísticas que describen la media o el centro de los datos las llamamos **parámetros de ubicación o medidas de tendencia central**.

Medidas de tendencia central: Media Aritmética

Supongamos que una variable de tamaño n consiste en los valores $x_1, x_2, \dots, x_n$. La **media aritmética** de estos datos se define como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Para datos agrupados en tablas de frecuencia.

$$\bar{x} = \sum_{i=1}^n f_i m_i$$

Donde m_i es la marca de clase en datos continuos o la clase para datos discretos.

Ejemplo

Supongamos que alguien de Múnich (Alemania) planea unas vacaciones en Bangkok (Tailandia) durante el mes de diciembre y quiere obtener información sobre el clima para preparar su viaje. Supongamos que las temperaturas máximas diurnas (en grados Celsius) del año pasado para el período del 1 al 31 de diciembre fueron las siguientes:

22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26,
25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

Determine la media aritmética de los datos

Propiedades de la media aritmética

- ▶ $\sum_{i=1}^n (x_i - \bar{x}) = 0$
- ▶ Si a los datos se le aplica una transformación lineal como $y_i = a + bx_i$, donde a y b son constantes conocidas, entonces,

$$\bar{y} = a + b\bar{x}$$

Ejemplo

En el ejemplo anterior, medimos las temperaturas en grados Celsius, pero es posible que alguien de Estados Unidos prefiera conocerlas en grados Fahrenheit. Mediante una transformación lineal, podemos crear una nueva variable de temperatura como:

$$\text{Temperatura en F} = 32 + 1,8 \times \text{Temperatura en C.}$$

Determine la media en grados Fahrenheit.

Medidas de tendencia central: La mediana

La **mediana** es el valor que divide las observaciones en dos partes iguales, de manera que al menos el 50 % de los valores son mayores o iguales a la mediana y al menos el 50 % de los valores son menores o iguales a la mediana.

Medidas de tendencia central: La mediana

Considere las n observaciones $x_1, x_2, \dots, x_n$ que se pueden ordenar como $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. El cálculo de la mediana depende de si el número de observaciones n es par o impar. Cuando n es impar, entonces $x_{0,5}$ es el valor medio ordenado. Cuando n es par, entonces $x_{0,5}$ es la media aritmética de los dos valores medios ordenados.

$$x_{0,5} = \begin{cases} x_{((n+1)/2)} & \text{si } n \text{ es impar} \\ \frac{1}{2} (x_{(n/2+1)} + x_{(n/2)}) & \text{si } n \text{ es par} \end{cases}$$

Medidas de tendencia central: La mediana

Para datos agrupados. Sean $K_1, K_2, \dots, K_k$ las k clases con frecuencias relativas $f_1, \dots, f_k$, respectivamente. Primero, necesitamos determinar cuál es la clase que incluye la mediana. Definimos la clase mediana como la clase K_m para la cual se verifica


$$\sum_{i=1}^{m-1} f_i < 0,5 \text{ y } \sum_{i=1}^m f_i \geq 0,5$$

Y luego calculamos la mediana, como


$$x_{0,5} = l_{m-1} + \frac{0,5 - \sum_{i=1}^{m-1} f_i}{f_m} \times d_m$$

Donde l_{m-1} es el límite inferior de K_m y d_m es el ancho de K_m .


Comparación entre media y mediana




(a) Symmetric data



(b) Skewed data



(c) Bimodal data



(d) Data with outliers

Ejemplo

Supongamos que alguien de Múnich (Alemania) planea unas vacaciones en Bangkok (Tailandia) durante el mes de diciembre y quiere obtener información sobre el clima para preparar su viaje. Supongamos que las temperaturas máximas diurnas (en grados Celsius) del año pasado para el período del 1 al 31 de diciembre fueron las siguientes:

22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26,
25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

Determine la mediana de los datos

Medidas de tendencia central: La moda

La moda X_M de n observaciones $x_1, x_2, \dots, x_n$ es el valor que aparece con mayor frecuencia en comparación con todos los demás valores. Puede suceder que dos o más valores tengan la misma frecuencia, en cuyo caso la moda no está definida de manera única. La moda se suele aplicar a cualquier tipo de variable para la cual el número de valores diferentes no sea demasiado grande.

Medidas de tendencia central: La moda

Si los datos continuos se resumen en grupos, también se puede utilizar la moda. Para calcular la moda en continuos, considere K_M La clase que tiene mayor frecuencia absoluta. Luego se calcula

$$x_M = l_{M-1} + \left(\frac{f_M - f_{M-1}}{2f_M - f_{M-1} - f_{M+1}} \right) d_M$$

donde l_{M-1} es el límite inferior K_M , f_{M-1} , f_M y f_{M+1} son las frecuencias de las clases K_{M-1} , K_M y K_{M+1} respectivamente, y d_M es el ancho de K_M .

Ejemplo

Imagina que hay diez personas en la fila del supermercado. Cada una de ellas está codificada como "F"(si es mujer) o "M"(si es hombre). Los datos recopilados podrían verse así:

M, F, M, F, M, M, M, F, M, M.

Determine la Moda.

Cuantiles

Los **cuantiles** son una generalización de la idea de la mediana. La mediana es el valor que divide los datos en dos partes iguales. El percentil $(\alpha \times 100) \%$, denotado como x_α , se define como el valor que divide los datos en proporciones de $(\alpha \times 100) \%$ y $(1 - \alpha) \times 100 \%$ de modo que al menos $\alpha \times 100 \%$ de los valores sean menores o iguales al percentil y al menos $(1 - \alpha) \times 100 \%$ de los valores sean mayores o iguales al percentil.

Cuantiles

Considere las n observaciones $x_1, x_2, \dots, x_n$ que se pueden ordenar como $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.

$$x_{\alpha} = \begin{cases} x_k & \text{si } \alpha n \text{ no es un entero} \\ & \text{escoja k el menor entero } > \alpha n \\ \frac{1}{2} (x_{(\alpha n+1)} + x_{(\alpha n)}) & \text{si } \alpha n \text{ es entero} \end{cases}$$

Si $\alpha = 0,1,0,2, \dots, 0,9$ los cuantiles son llamados **deciles**. Si $\alpha = 0,2,0,4,0,6,0,8$ los cuantiles se llaman quintiles. Si $\alpha = 0,25,0,5,0,75$ los cuantiles son llamados **cuartiles**.

Ejemplo

Supongamos que alguien de Múnich (Alemania) planea unas vacaciones en Bangkok (Tailandia) durante el mes de diciembre y quiere obtener información sobre el clima para preparar su viaje. Supongamos que las temperaturas máximas diurnas (en grados Celsius) del año pasado para el período del 1 al 31 de diciembre fueron las siguientes:

22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26,
25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

Determine los cuartiles.

Rango y rango intercuantílico

Consideremos una variable X con n observaciones ordenadas de menor a mayor $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. El **rango** es una medida de dispersión definida como la diferencia entre el valor máximo y el mínimo de los datos:

$$R = x_{(n)} - x_{(1)}$$

El **rango intercuartílico** (RIQ) se define como la diferencia entre el cuartil 75 (Q3) y el cuartil 25 (Q1):

$$RIQ = x_{0,75} - x_{0,25}$$

Varianza y desviación estándar

Supongamos que una variable de tamaño n consiste en los valores $x_1, x_2, \dots, x_n$. La **varianza** de estos datos se define como:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \bar{x}^2$$

Para datos agrupados en tablas de frecuencia.

$$s^2 = \sum_{i=1}^k f_i (m_i - \bar{x})^2 = \sum_{i=1}^k f_i m_i^2 - \bar{x}^2$$

Donde m_i es la marca de clase en datos continuos o la clase para datos discretos.

Varianza y desviación estándar

La desviación estándar (muestral) se define como la raíz de la varianza, es decir,

$$s = \sqrt{s^2}$$

La desviación estándar tiene la misma unidad de medida que los datos, mientras que la unidad de la varianza es el cuadrado de las unidades de las observaciones.

Ejemplo

Supongamos que alguien de Múnich (Alemania) planea unas vacaciones en Bangkok (Tailandia) durante el mes de diciembre y quiere obtener información sobre el clima para preparar su viaje. Supongamos que las temperaturas máximas diurnas (en grados Celsius) del año pasado para el período del 1 al 31 de diciembre fueron las siguientes:

22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26,
25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

Determine rango, RIQ, varianza y desviación estándar.

Coeficiente de variación

Consideremos una situación en la que dos variables diferentes tienen medias aritméticas $\bar{x}_1$ y $\bar{x}_2$ con desviaciones estándar s_1 y s_2 , respectivamente. Supongamos que queremos comparar la variabilidad de los precios de los hoteles en Múnich (medidos en euros) y en Londres (medidos en libras esterlinas). ¿Cómo podemos hacer una comparación justa? Dado que los precios se miden en unidades diferentes y, por tanto, es probable que sus medias aritméticas difieran sustancialmente, no tiene mucho sentido comparar directamente las desviaciones estándar.

Coeficiente de variación

El coeficiente de variación v es una medida de dispersión que utiliza tanto la desviación estándar como la media, lo que permite una comparación justa. Se define correctamente sólo cuando todos los valores de una variable se miden en una escala de razón y son positivos, de modo que se debe cumplir $\bar{x} > 0$. Este se define como,

$$v = \frac{s}{\bar{x}}$$

El coeficiente de variación es una medida de dispersión sin unidades.



Coeficiente de variación

Si queremos comparar la variabilidad de los precios de los hoteles en dos ciudades seleccionadas de Alemania e Inglaterra, podríamos calcular los precios medios, junto con su desviación estándar. Supongamos que tenemos una muestra de precios de, digamos, 100 hoteles en dos ciudades seleccionadas de Alemania e Inglaterra y que obtenemos las medias y las desviaciones estándar de las dos ciudades como $\bar{x}_1 = 130$ euros, $\bar{x}_2 = 230$ libras, $s_1 = 99$ euros y $s_2 = 212$ libras. ¿Cual de los dos precios tiene mayor variabilidad?

Box-plot

Hasta ahora hemos descrito varias medidas de tendencia central y dispersión. Puede ser tedioso enumerar esas medidas en tablas de resumen. Un gráfico simple y poderoso es el diagrama de caja, que resume la distribución de una variable continua (o a veces ordinal) utilizando su mediana, cuartiles, mínimo, máximo y valores extremos.

Box-plot



Ejemplo

Supongamos que alguien de Múnich (Alemania) planea unas vacaciones en Bangkok (Tailandia) durante el mes de diciembre y quiere obtener información sobre el clima para preparar su viaje. Supongamos que las temperaturas máximas diurnas (en grados Celsius) del año pasado para el período del 1 al 31 de diciembre fueron las siguientes:

22, 24, 21, 22, 25, 26, 25, 24, 23, 25, 25, 26, 27, 25, 26,
25, 26, 27, 27, 28, 29, 29, 29, 28, 30, 29, 30, 31, 30, 28, 29.

Construya el box-plot para estos datos