

Estadística inferencial

Andrés Felipe Puerta Velez

andres.puerta-v@uniminuto.edu.co

CBASBL061

Sesión 15 — Semana 15 · 16 al 21 de
noviembre de 2026

Orden del día

1. Llamado a lista y revisión de los ejercicios propuestos
2. Repaso: dónde quedamos
3. **Tema 3.5: correlación y regresión lineal**
4. **Tema 3.6: validación de modelos**
5. Ejercicios en clase
6. **Repaso para el Examen 3**

Repaso: dónde quedamos

Todo el curso ha trabajado con **una** variable: estimar su media, su proporción, contrastar hipótesis sobre ella.

El último paso

Hoy trabajamos con **dos** variables a la vez y respondemos dos preguntas nuevas: ¿están relacionadas y qué tan fuerte? (correlación) y ¿puedo usar una para predecir la otra? (regresión).

Con esto se cierra la unidad 3 y el curso. El **Examen 3** es la próxima semana: 23 al 28 de noviembre.

3.5 Correlación

Coeficiente de correlación de Pearson

Fórmula

$$r = \frac{n \sum xy - \sum x \sum y}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}}$$

Qué mide

La fuerza y el sentido de la relación **lineal**. Siempre $-1 \leq r \leq 1$.

Cómo se lee

$r > 0$: crecen juntas. $r < 0$: una sube y la otra baja.
 $r \approx 0$: no hay relación *lineal* (podría haber otra).

$|r| < 0,3$ débil • 0,3 a 0,7 moderada • $> 0,7$ fuerte

Correlación no es causalidad

La advertencia más importante de la sesión

Que dos variables se muevan juntas no significa que una cause la otra. Un r alto puede deberse a:

- Una **tercera variable** que afecta a ambas (el tamaño de la ciudad explica a la vez ventas y número de empleados).
- Coincidencia en muestras pequeñas.
- Causalidad **inversa**: quizá y causa x .

Para afirmar causalidad hace falta más

Un diseño experimental con asignación aleatoria, o al menos control de las variables que podrían confundir. La estadística descriptiva de la relación no basta.

3.5 Regresión lineal simple

La recta de regresión

Modelo

$$\hat{y} = b_0 + b_1 x \quad b_1 = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2} \quad b_0 = \bar{y} - b_1 \bar{x}$$

Interpretación de b_1

Cuánto cambia y en promedio por cada unidad que aumenta x . Es la pendiente.

Interpretación de b_0

Valor estimado de y cuando $x = 0$. A veces no tiene sentido práctico: depende de si $x = 0$ es un valor posible.

Los coeficientes se obtienen por **mínimos cuadrados**: la recta que hace mínima la suma de los cuadrados de los residuos $e_i = y_i - \hat{y}_i$.

Ejercicio 1 — en clase

En parejas (12 minutos)

Una empresa registra la inversión en publicidad (x , millones) y las ventas (y , millones) de 8 meses:

x	2	4	5	7	8	10	12	14
y	35	40	52	55	68	70	78	88

Sumas: $\sum x = 62$, $\sum y = 486$, $\sum xy = 4287$, $\sum x^2 = 598$, $\sum y^2 = 31906$.

1. Calcule r e interprételo.
2. Obtenga la recta $\hat{y} = b_0 + b_1 x$.
3. Prediga las ventas con una inversión de 9 millones.

Ejercicio 1 — solución

Cálculos

$$b_1 = \frac{8(4287) - 62(486)}{8(598) - 62^2} = \frac{34296 - 30132}{4784 - 3844} = \mathbf{4,4298}$$

$$b_0 = \frac{486}{8} - 4,4298 \left(\frac{62}{8} \right) = \mathbf{26,4191}$$

$$r = \mathbf{0,9840} \quad r^2 = \mathbf{0,9682}$$

Recta y predicción

$$\hat{y} = 26,42 + 4,43 x$$

$$\hat{y}(9) = 26,42 + 4,43(9) = \mathbf{66,29}$$

Interpretación

Correlación positiva **fuerte**. Por cada millón adicional de publicidad, las ventas aumentan en promedio 4,43 millones.

3.6 Validación de modelos

Coeficiente de determinación r^2

Qué significa

r^2 es la **proporción de la variabilidad de y que el modelo explica**. Se expresa como porcentaje y va de 0 a 1.

En el ejercicio

$r^2 = 0,9682$: el 96,8 % de la variación en las ventas se explica por la inversión en publicidad. El 3,2 % restante se debe a otros factores no incluidos en el modelo.

Un r^2 alto no valida el modelo por sí solo

Puede haber un r^2 alto con una relación claramente curva, o con datos dominados por un solo valor atípico. Siempre hay que **graficar**.

Cómo validar el modelo

1. **Graficar la dispersión** antes de ajustar: ¿la nube es realmente lineal?
2. **Revisar los residuos** $e_i = y_i - \hat{y}_i$: deben repartirse al azar alrededor de cero, sin patrones ni curvatura.
3. **Detectar atípicos** e influyentes: un punto lejano puede arrastrar toda la recta.
4. **Probar la significancia** de la pendiente: $H_0 : \beta_1 = 0$ contra $H_1 : \beta_1 \neq 0$. Si no se rechaza, la variable x no aporta.
5. **No extrapolar**: la recta solo es creíble dentro del rango de x observado.

Sobre el punto 5

Predecir las ventas con una inversión de 60 millones a partir de datos entre 2 y 14 no tiene respaldo: nada garantiza que la relación siga siendo lineal fuera de ese rango.

Ejercicio 2 — en clase

Individual (9 minutos)

Con el modelo $\hat{y} = 26,42 + 4,43 x$ del ejercicio anterior:

1. Calcule el valor estimado para $x = 8$ y el residuo correspondiente (el valor observado fue $y = 68$).
2. Interprete $b_0 = 26,42$ en el contexto del problema.
3. ¿Sería válido predecir las ventas con $x = 60$? Justifique.
4. ¿Puede concluirse que la publicidad *causa* las ventas?

Ejercicio 2 — solución

Punto 1

$\hat{y}(8) = 26,42 + 4,43(8) = \mathbf{61,86}$ y el residuo es $e = 68 - 61,86 = \mathbf{6,14}$: ese mes se vendió más de lo que el modelo predecía.

Puntos 2 y 3

b_0 sería la venta estimada sin publicidad: 26,42 millones. Es interpretable aquí porque $x = 0$ es un escenario posible, aunque queda fuera del rango observado.

Con $x = 60$ **no**: sería extrapolar muy lejos del rango de 2 a 14.

Punto 4

No. La correlación es fuerte, pero pudo haber una tercera variable (temporada, crecimiento del mercado) que moviera ambas.

Repaso para el Examen 3

Mapa de la Unidad 3

Tema	Sesión	Lo esencial
Concepto	13	H_0 lleva la igualdad; H_1 es lo que se prueba
Tipos	13	Bilateral ($\neq$) o unilateral ($>$, $<$)
Errores	13	Tipo I (α) y tipo II (β); potencia $1 - \beta$
Valor p	13	Si $p \leq \alpha$ se rechaza H_0
Pasos	14	Plantear, fijar α , región, calcular, concluir
Estadísticos	14	z con σ ; t con s ; proporción con p_0
Software	14	Leer p , gl y el IC de la salida
Correlación	15	$r \in [-1, 1]$; no implica causalidad
Regresión	15	$\hat{y} = b_0 + b_1 x$; r^2 explica la variabilidad

Examen 3 — semana 16

23 al 28 de noviembre, en Aulas Virtuales (Moodle), presencial, individual. Vale el **33,4 %**. Traiga calculadora, formulario y tablas de Z y t .

Correlación y regresión, en R

```
x <- c(2, 4, 5, 7, 8, 10, 12, 14) # inversion en publicidad
y <- c(35, 40, 52, 55, 68, 70, 78, 88) # ventas

cor(x, y) # coeficiente de Pearson
modelo <- lm(y ~ x) # se lee "y en funcion de x"
coef(modelo) # b0 y b1
summary(modelo)$r.squared # coeficiente de determinacion
predict(modelo, data.frame(x = 9)) # prediccion

plot(x, y, pch = 19, main = "Ventas segun publicidad")
abline(modelo, col = "tomato", lwd = 2) # la recta ajustada
plot(fitted(modelo), residuals(modelo)) # validacion: residuos
```

```
[1] 0.9839578
(Intercept) x
 26.419149 4.429787
[1] 0.9681725
 1
66.28723
```

Lo que R no le va a decir

Que $r = 0.98$ **no prueba** que la publicidad cause las ventas; que predecir en $x = 40$ sería extrapolar fuera del rango observado; y que con $n = 8$ cualquier conclusión es frágil. **Esos tres juicios son suyos**, y son los que se evalúan en el Examen 3.

Cierre del curso

El recorrido completo

- **Unidad 1:** describir y contar lo incierto; medir con probabilidad; elegir una muestra.
- **Unidad 2:** modelar el azar con distribuciones; entender que $\bar{X}$ es aleatoria; estimar con intervalos.
- **Unidad 3:** decidir con evidencia; relacionar y predecir.

La idea que resume el curso

Nunca vamos a conocer la población. Lo que la estadística inferencial ofrece no es certeza, sino **una medida honesta de cuánta incertidumbre queda** después de mirar los datos. Esa medida es lo que permite decidir sin engañarse.

Ejercicios propuestos

1–12: datos del ejercicio 1 ($\sum x = 62$, $\sum y = 486$, $\sum xy = 4287$, $\sum x^2 = 598$, $\sum y^2 = 31906$, $n = 8$).

1. $\bar{x}$
2. $\bar{y}$
3. b_1
4. b_0
5. Ecuación de la recta
6. r
7. r^2 en porcentaje
8. $\hat{y}$ para $x = 9$
9. $\hat{y}$ para $x = 6$
10. Residuo en $x = 8$ si $y = 68$
11. Interprete b_1
12. ¿Es válido predecir con $x = 60$?
13. Rango de valores posibles de r
14. $r = -0,85$: ¿fuerza y sentido?
15. $r = 0,12$: ¿fuerza?
16. ¿ r alto implica causalidad?
17. ¿Qué mide r^2 ?
18. ¿Qué se revisa en los residuos?
19. H_0 y H_1 para la significancia de la pendiente
20. Si no se rechaza H_0 del punto 19, ¿qué se concluye?

Respuestas

Autoevaluación de los ejercicios propuestos

1. 7,75
2. 60,75
3. 4,4298
4. 26,4191
5. $\hat{y} = 26,42 + 4,43x$
6. 0,9840
7. 96,82 %
8. 66,29
9. 53,00
10. 6,14
11. Por cada millón más de publicidad, las ventas suben 4,43
12. No: extrapolación fuera del rango 2–14
13. $-1 \leq r \leq 1$
14. Fuerte y negativa
15. Muy débil
16. No
17. La proporción de variabilidad de y explicada
18. Que se repartan al azar, sin patrón
19. $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$
20. Que x no aporta a explicar y

Referencias

- [1] Díaz Rodríguez, M. (2022). *Estadística inferencial aplicada*. Universidad del Norte.
<https://elibro.net/es/lc/uniminuto/titulos/221614>
- [2] Llinás Solano, H. (2014). *Introducción a la estadística con aplicaciones en ciencias sociales*. Universidad del Norte. <https://elibro.net/es/lc/uniminuto/titulos/70062>
- [3] Contento Rubio, M. R. (2019). *Estadística con aplicaciones en R*. Editorial Utadeo.
<https://elibro.net/es/lc/uniminuto/titulos/220926>

Éxitos en el Examen 3